



Tarea #2: INF398 - Introducción al Aprendizaje Automático

Introducción General

El objetivo de esta tarea es que los estudiantes integren, de forma práctica y crítica, los contenidos de la segunda mitad del curso: árboles de decisión (T5), métodos de ensamble por bagging y Random Forest (T6), boosting (T7), aprendizaje no supervisado y clustering (T8), y reducción de dimensionalidad (T9).

Para ello, se entregan **datasets sintéticos opacos**: las columnas no tienen nombres descriptivos ($X_1, X_2, \dots, X_p$) y los datasets se identifican mediante letras (A, B, ..., E). Cada dataset esconde un **fenómeno específico** construido para que una decisión metodológica concreta — podar un árbol, preferir un ensamble, regularizar el boosting, elegir el número de clusters, o reducir con un criterio supervisado — sea la diferencia entre acertar y fracasar. La tarea consiste en **diagnosticar** ese fenómeno a partir de los datos, sin metadata semántica, y elegir la técnica con fundamento.

Cada dataset evalúa la capacidad de:

- Realizar un análisis exploratorio (EDA) dirigido a las propiedades que importan al método (forma de las nubes, escalas dispares, cardinalidad de variables, separabilidad, varianza del estimador).
- Aplicar **al menos dos técnicas en competencia** del tema correspondiente y compararlas honestamente.
- Tomar la **decisión metodológica** central del tema con un criterio explícito (poda por CV, importancia por permutación, regularización del boosting, selección de K , número de componentes).
- Diagnosticar el fenómeno escondido y justificar la técnica ganadora a la luz de la evidencia.
- Reportar el artefacto de test con la métrica adecuada al régimen del problema.

Modalidad:

- Trabajo en grupos de **2 o 3 estudiantes**. Los grupos de 2 personas resuelven **4 datasets** (A a D); los grupos de 3 personas resuelven los **5 datasets** (A a E).
- La fecha límite de entrega es el **viernes 03 de Julio** a las **23:55**. Toda entrega posterior a esa hora será **evaluada con nota 0**, sin excepciones.
- Entrega en formato **Jupyter Notebook autocontenido**. El archivo debe nombrarse exactamente `L2_rol1_rol2_{rol3}.ipy`. Para grupos de 2 personas: `L2_rol1_rol2.ipynb`; para grupos de 3 personas: `L2_rol1_rol2_rol3.ipynb`. **No cumplir con este formato implica un descuento de 5 puntos.**
- Todo el desarrollo, análisis, gráficos, modelos finales y conclusiones deben estar en un solo notebook ejecutable.
- Junto al notebook, se entrega un archivo de resultados `resultados_L2_rol1_rol2_{rol3}.h5` con los artefactos sobre el conjunto de test (ver formato más abajo).
- Pueden encontrar la plantilla de referencia y el archivo `datasets_train.h5` en la página oficial de la asignatura en Aula.
- El código debe ser eficiente y reproducible: fijar `random_state` en todos los splits, modelos estocásticos y algoritmos de clustering.
- Toda visualización debe estar debidamente interpretada en el texto.

Uso de asistentes de IA:



- Está **permitido** el uso de asistentes de IA (ChatGPT, Claude, Copilot, etc.) durante el desarrollo de la tarea.
- Sin embargo, se exige **declaración explícita** del uso. Al inicio del notebook debe incluirse una celda Markdown titulada **Declaración de uso de IA** con la siguiente información:
 - Asistente(s) utilizado(s) y versión.
 - En qué etapa(s) se utilizó (EDA, preparación, métodos en competencia, decisión, redacción, depuración).
 - Para cada uso significativo, adjuntar el prompt utilizado y una breve descripción de cómo se incorporó (o descartó) la respuesta.
- La omisión de esta declaración cuando hubo uso de IA será considerada falta académica.

Notas:

- El archivo `datasets_train.h5` es el mismo para todo el curso. Aun así, los grupos no pueden compartir código, gráficos ni interpretaciones: cada grupo debe llegar a sus propias conclusiones de manera independiente. Las similitudes sospechosas entre entregas serán evaluadas según normativa.
- El archivo `datasets_test.h5` **no será entregado a los estudiantes**. Será utilizado por el profesor para evaluar los artefactos finales aplicando el pipeline entregado por el grupo. La métrica obtenida sobre el set de test influye directamente en la nota.
- Se recomienda estructurar el código de manera que la aplicación del pipeline a nuevos datos sea automática y reproducible, sin intervención manual.
- El incumplimiento de plazos, formato o reproducibilidad será considerado en la evaluación.

Estructura de los datos

El archivo `datasets_train.h5` contiene 5 grupos (A a E). Los grupos de 2 personas trabajan únicamente con A a D; los grupos de 3 personas resuelven los 5. Cada grupo expone los siguientes arreglos:

```
1 import h5py
2
3 def cargar_datasets_desde_h5(archivo_h5):
4     datasets = {}
5     with h5py.File(archivo_h5, "r") as f:
6         for grupo in f:
7             datasets[grupo] = {}
8             for key in f[grupo]:
9                 datasets[grupo][key] = f[grupo][key][:]
10    return datasets
11
12 datasets_train = cargar_datasets_desde_h5("datasets_train.h5")
13
14 # Acceso a los datos del dataset 'A':
15 X_train = datasets_train['A']['X_train']      # forma (n_train, p)
16 y_train = datasets_train['A']['y_train']      # forma (n_train,)
17 X_test  = datasets_train['A']['X_test']      # forma (n_test, p), sin etiquetas
18
19 print(X_train.shape, y_train.shape, X_test.shape)
```

Sobre los grupos sin etiqueta (clustering). El dataset de clustering (D) expone `X_train` y `X_test`, pero `y_train` **no** contiene la verdad de los clusters: es un marcador de relleno y no debe usarse como supervisión. La asignación verdadera sobre el test permanece oculta y se usa solo para corregir.

Sobre las columnas: Las features no tienen nombre semántico. Algunas pueden ser categóricas codificadas como enteros (incluyendo variables de **alta cardinalidad**); otras son continuas. Detectar el tipo y la cardinalidad de cada feature es parte del análisis.

Formato de entrega de resultados. Cada dataset entrega un **artefacto** sobre **X_test**, bajo una clave fija. El tipo de artefacto y la métrica dependen del dataset:

Dataset	Clave en el .h5	Artefacto	Métrica de corrección
A	A/y_pred	Etiqueta predicha por fila de X_test	Accuracy / F1
B	B/relevantes	Índices (0-based) de columnas relevantes	Índice de Jaccard
C	C/y_pred	Etiqueta predicha por fila de X_test	Accuracy sobre test limpio
D	D/labels	Cluster asignado por fila de X_test	ARI / NMI
E	E/y_pred	Etiqueta predicha por fila de X_test	Accuracy

```
1 import h5py, numpy as np
2
3 # Para grupos de 2: resultados_L2_rol1_rol2.h5 (claves A..D)
4 # Para grupos de 3: resultados_L2_rol1_rol2_rol3.h5 (claves A..E)
5 with h5py.File("resultados_L2_rol1_rol2.h5", "w") as f:
6     f.create_dataset("A/y_pred", data=np.asarray(y_pred_A, dtype=np.int64))
7     f.create_dataset("B/relevantes", data=np.asarray(idx_rel_B, dtype=np.int64))
8     f.create_dataset("C/y_pred", data=np.asarray(y_pred_C, dtype=np.int64))
9     f.create_dataset("D/labels", data=np.asarray(labels_D, dtype=np.int64))
10    # Solo grupos de 3:
11    # f.create_dataset("E/y_pred", data=np.asarray(y_pred_E, dtype=np.int64))
```

Reglas del artefacto:

- Para A, C, E y D, el arreglo debe tener **una entrada por fila de X_test**, en el **mismo orden** que las filas originales. Orden distinto invalida el dataset.
- Para D/labels, las etiquetas de cluster son arbitrarias: la corrección usa ARI/NMI, invariantes a la permutación de los identificadores. Solo importa la partición, no qué número recibe cada grupo.
- Para B/relevantes, entregue el conjunto de índices de columna (0-based) que su análisis concluye que son las variables **realmente** predictivas. El conjunto puede tener cualquier tamaño; se compara contra la verdad por Jaccard.

Herramientas y funciones recomendadas

A continuación se listan funciones de **scikit-learn** y librerías relacionadas que cubren la mayor parte de la tarea. **No todas son necesarias para todos los datasets:** parte del ejercicio consiste en decidir cuáles aplicar en cada caso.

Análisis exploratorio:

- `pandas.DataFrame.describe()`, `.corr()`, `.unique()`, `.value_counts()` (clave para detectar cardinalidad).
- `seaborn.heatmap`, `seaborn.pairplot`, `seaborn.scatterplot`, `matplotlib.pyplot`.
- Proyecciones 2D para inspeccionar la forma de las nubes (e.g., `PCA(n_components=2)` solo para visualizar).

Preprocesamiento y codificación:

- Escaladores: `StandardScaler`, `RobustScaler`, `MinMaxScaler`.
- Codificación de categóricas: `OneHotEncoder`, `OrdinalEncoder` (cuidado con la alta cardinalidad).



- Composición: `ColumnTransformer` para tratar numéricas y categóricas por separado.

Árboles y poda (T5):

- `DecisionTreeClassifier`, `DecisionTreeRegressor`.
- Poda por costo-complejidad: método `cost_complexity_pruning_path` del estimador, combinado con `GridSearchCV` sobre `ccp_alpha`; considere la regla *one-standard-error*.
- Visualización: `sklearn.tree.plot_tree`, `export_text`.

Ensamblados (T6):

- `RandomForestClassifier`, `BaggingClassifier` (con `oob_score=True`).
- Importancia: `feature_importances_` (MDI) y `sklearn.inspection.permutation_importance`. **Contraste obligatorio cuando haya variables de cardinalidad dispar.**

Boosting (T7):

- `GradientBoostingClassifier`, `HistGradientBoostingClassifier` (con `learning_rate`, `early_stopping`, `validation_fraction`).
- Opcional: `xgboost`, `lightgbm` (no requeridos; los ensambles de `scikit-learn` bastan).

Clustering (T8):

- `KMeans`, `MiniBatchKMeans`, `GaussianMixture` (`covariance_type='full'`), `AgglomerativeClustering`.
- Dendrograma: `scipy.cluster.hierarchy.linkage` y `dendrogram`.
- Selección de *K*: `inertia_` (codo), `silhouette_score`, gap statistic (referencia nula), `GaussianMixture.bic`. *Triangular* entre criterios.

Reducción de dimensionalidad (T9):

- PCA (`explained_variance_ratio_` para el scree plot), `TruncatedSVD`.
- `sklearn.discriminant_analysis.LinearDiscriminantAnalysis` (LDA), como reductor supervisado y/o clasificador.

Validación y métricas:

- Splits y CV: `train_test_split`, `KFold`, `StratifiedKFold`, `cross_val_score`, `GridSearchCV`.
- Clasificación: `accuracy_score`, `f1_score`, `balanced_accuracy_score`, `confusion_matrix`.
- Clustering: `adjusted_rand_score`, `normalized_mutual_info_score`, `adjusted_mutual_info_score`, `silhouette_score`.

Tips para construir pipelines correctos

1. **Encapsule el preprocesamiento en Pipeline.** El scaler, encoder o reductor debe ajustarse *solo en el train* de cada fold de CV. Para reducción supervisada (LDA) y para PCA, ajustar sobre el test es fuga de datos.

```
1 from sklearn.pipeline import Pipeline
2 from sklearn.preprocessing import StandardScaler
3 from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
4 from sklearn.linear_model import LogisticRegression
5 from sklearn.model_selection import cross_val_score
6
7 # Reducir con LDA y luego clasificar: el LDA se ajusta dentro del fold
```

```
8 pipe = Pipeline([
9     ("scaler", StandardScaler()),
10    ("lda", LinearDiscriminantAnalysis(n_components=1)),
11    ("clf", LogisticRegression(max_iter=1000, random_state=42)),
12 ])
13 print(cross_val_score(pipe, X_train, y_train, cv=5, scoring="accuracy").mean())
```

2. En clustering, escale antes de medir distancias. K-means y GMM dependen de la escala. Decida y justifique el escalado. El silhouette es $O(N^2)$: en datasets grandes, submuestree para estimarlo.

3. Errores comunes a evitar:

- **Fuga de datos:** ajustar un `StandardScaler`, `PCA` o `LDA` sobre `X_train` y `X_test` concatenados. Solución: pipeline + CV.
- **Test contaminado por EDA:** realizar gráficos o estadísticas con `X_test`. `X_test` solo aparece al final, para generar el artefacto.
- **Hiperparámetros tuneados sobre el test:** el test del archivo `.h5` no debe usarse para elegir K , `ccp_alpha`, número de componentes ni nada.
- **Usar la importancia MDI como conclusión final** cuando hay cardinalidades dispares: confirme siempre con `permutation_importance`.
- **No fijar `random_state`:** los resultados no son reproducibles y la pauta no puede verificarlos.

Metodología obligatoria por dataset

Para **cada** dataset asignado al grupo, el reporte debe seguir las siguientes **cinco etapas**. Cada etapa contiene preguntas obligatorias que deben responderse explícitamente en celdas Markdown del notebook. Donde la pregunta dependa del régimen (supervisado / clustering / reducción), responda lo que corresponda al dataset.

Etapas 1. EDA dirigido (4 puntos)

Caracterice las propiedades que importan al método del tema.

Preguntas obligatorias:

- **E1.1** Caracterice el régimen (n, p) y el tipo de cada variable (continua / categórica) junto con su escala y **cardinalidad** (número de valores únicos).
- **E1.2** Según el régimen del dataset: para **supervisado**, distribución de y / balance de clases y evidencia visual de separabilidad o de no-linealidad; para **clustering**, forma de las nubes (esféricas vs elongadas), escalas dispares, indicios de número de grupos; para **reducción**, estructura de covarianza/correlación y direcciones de mayor dispersión.
- **E1.3** ¿Qué hipótesis preliminar sugiere el EDA sobre el fenómeno escondido? (sin todavía aplicar modelos).

Etapas 2. Preparación y representación (4 puntos)

Decida y justifique las transformaciones previas al modelamiento.

Preguntas obligatorias:

- **E2.1** ¿Escala o estandariza? Justifique en términos del método (los árboles son invariantes a escalas monótonas; k-means, GMM, PCA y LDA **no** lo son).
- **E2.2** ¿Cómo trata las variables categóricas, en particular las de **alta cardinalidad**? Discuta el riesgo de codificarlas ingenuamente.
- **E2.3** Para reducción/clustering: ¿centra los datos? ¿usa matriz de covarianza o de correlación? Justifique.



Etapa 3. Métodos en competencia (4 puntos)

Aplice **al menos dos enfoques rivales** del tema y compárelos honestamente con validación interna (CV, OOB o índices internos). *Nunca* use el test del .h5 para comparar.

Preguntas obligatorias (responda según el dataset):

- **Árboles (T5):** árbol completo vs árbol **podado** por costo-complejidad. Reporte la curva de error CV vs `ccp_alpha` y la brecha train/CV antes y después de podar.
- **Ensamblados (T6):** árbol único vs Random Forest (use `oob_score`). Compare la **importancia MDI** con la **importancia por permutación** y describa cualquier discrepancia.
- **Boosting (T7):** boosting sin regularizar vs boosting regularizado (`learning_rate` bajo + `early_stopping`) vs un ensamble de bagging/RF. Reporte cómo evoluciona el error de validación con el número de iteraciones.
- **Clustering (T8):** al menos dos de {k-means, GMM con covarianza completa, jerárquico}, para un rango de K . Reporte una métrica interna (silhouette) por K y, para GMM, el BIC.
- **Reducción (T9):** clasificar tras reducir con **PCA** vs reducir con **LDA** vs sin reducir. Reporte el scree plot de PCA y el desempeño CV downstream de cada alternativa.

Etapa 4. Decisión con criterio (4 puntos)

Tome la decisión central del tema con un criterio explícito y reproducible.

Preguntas obligatorias (responda según el dataset):

- **T5:** ¿qué `ccp_alpha` elige y bajo qué regla (mínimo CV o one-standard-error)? ¿Qué complejidad de árbol implica?
- **T6:** ¿qué subconjunto de features declara realmente relevante y con qué criterio de importancia? Justifique por qué descarta las que la MDI privilegia.
- **T7:** ¿qué configuración elige como robusta y por qué? Diagnostique si hay **ruido de etiquetas** y argumente su efecto sobre boosting vs bagging.
- **T8:** ¿qué K elige y cómo *triangula* entre codo, silhouette, gap y/o BIC? ¿Qué algoritmo y por qué (forma de los clusters)?
- **T9:** ¿qué método de reducción y cuántas componentes elige? Si la **dirección de máxima varianza no coincide con la de máxima separación de clases**, explíquelo y fundamente la elección.

Etapa 5. Diagnóstico, decisión final y artefacto (4 puntos)

En una celda Markdown por dataset:

Preguntas obligatorias:

- **E5.1 Diagnóstico.** Nombre el fenómeno escondido y respáldelo con la evidencia de las etapas previas (gráfico, estadístico o resultado experimental).
- **E5.2 Pipeline final.** Indique el pipeline (transformaciones + modelo + hiperparámetros) que produce el artefacto de test, y justifíquelo a la luz del diagnóstico.
- **E5.3 Limitaciones.** ¿Bajo qué condiciones esperarías que su elección falle? ¿Qué técnica alternativa la mejoraría?

Total por dataset: 20 puntos.



Problemas

La metodología de las cinco etapas y sus preguntas obligatorias **aplican a todos los datasets por igual**, adaptadas al régimen de cada uno. La sección a continuación enumera los datasets con su información mínima de carga; los fenómenos no se revelan deliberadamente.

1. (20 puntos) Dataset A — Árboles (T5)

Régimen: Clasificación binaria.

Cargue `datasets_train['A']` y aplique las cinco etapas. Reporte las etiquetas predichas sobre `X_test` en `resultados_L2_rol1_` bajo la clave `A/y_pred`.

2. (20 puntos) Dataset B — Ensamblados (T6)

Régimen: Clasificación binaria.

Cargue `datasets_train['B']` y aplique las cinco etapas. Reporte el conjunto de índices de columna que considera realmente relevantes bajo la clave `B/relevantes`.

3. (20 puntos) Dataset C — Boosting (T7)

Régimen: Clasificación binaria.

Cargue `datasets_train['C']` y aplique las cinco etapas. Reporte las etiquetas predichas sobre `X_test` bajo la clave `C/y_pred`.

4. (20 puntos) Dataset D — Clustering (T8)

Régimen: Aprendizaje no supervisado (clustering).

Cargue `datasets_train['D']` y aplique las cinco etapas. Ajuste su modelo de clustering y reporte el cluster asignado a cada fila de `X_test` bajo la clave `D/labels`. El identificador numérico de cada cluster es libre; se corrige por ARI/NMI.

Dataset adicional (solo grupos de 3 personas):

5. (20 puntos) Dataset E — Reducción de dimensionalidad (T9)

Régimen: Clasificación binaria mediante una representación reducida.

Cargue `datasets_train['E']` y aplique las cinco etapas. Elija su esquema de reducción y clasificación, y reporte las etiquetas predichas sobre `X_test` bajo la clave `E/y_pred`.

Pauta de Revisión

Cálculo de la nota final

- **Grupos de 2 personas (4 datasets):** la suma de los 4 datasets totaliza 80 puntos. La nota final se calcula como

$$\text{nota} = \frac{\text{puntos obtenidos}}{80} \times 100.$$

- **Grupos de 3 personas (5 datasets):** la suma de los 5 datasets totaliza 100 puntos (nota directa).

Evaluación específica por dataset (20 puntos)

La rúbrica es la **misma para los 5 datasets**, dado que la metodología obligatoria aplica a todos por igual. Cada etapa vale 4 puntos:

- **Etapas 1 — EDA dirigido (4 puntos):**



- Caracterización del régimen (n, p) y de tipos/escala/cardinalidad de variables (1 pt).
- Análisis pertinente al régimen (separabilidad / forma de nubes / estructura de covarianza) bien interpretado (2 pts).
- Hipótesis preliminar fundamentada sobre el fenómeno (1 pt).
- **Etapla 2 — Preparación y representación (4 puntos):**
 - Decisión de escalado/estandarización correcta y justificada según el método (2 pts).
 - Tratamiento adecuado de categóricas y de la alta cardinalidad (1 pt).
 - Centrado / elección covarianza-correlación coherente cuando aplica (1 pt).
- **Etapla 3 — Métodos en competencia (4 puntos):**
 - Aplicación correcta de al menos dos enfoques rivales del tema (2 pts).
 - Comparación honesta con validación interna apropiada (CV / OOB / índices internos), sin fuga de datos (2 pts).
- **Etapla 4 — Decisión con criterio (4 puntos):**
 - Decisión central del tema tomada con criterio explícito y reproducible (2 pts).
 - Justificación correcta a la luz de la evidencia (poda / importancia / regularización / K / componentes) (2 pts).
- **Etapla 5 — Diagnóstico, decisión final y artefacto (4 puntos):**
 - Diagnóstico correcto del fenómeno, respaldado por evidencia (2 pts).
 - Pipeline final coherente con el diagnóstico y discusión de limitaciones (1 pt).
 - Artefacto de test correcto (formato, clave y orden) y desempeño en la métrica del dataset (1 pt).

Penalizaciones

- **Entrega después del viernes 03 de Julio a las 23:55: nota 0**, sin excepciones.
- Nombre de archivo distinto a `L2_rol1_rol2_{rol3}.ipynb`: -5 puntos.
- Falta de declaración de uso de IA cuando hubo uso: hasta -15 puntos (falta grave).
- Plagio o copia entre grupos: evaluación según normativa académica.
- Falta de reproducibilidad del código (semillas no fijas, paths absolutos, dependencias no declaradas): hasta -5 puntos por dataset afectado.
- EDA o ajuste de transformaciones sobre `X_train` y `X_test` concatenados (fuga de datos): -2 puntos por dataset afectado.
- Conclusión de importancia basada solo en MDI sin contraste por permutación cuando hay cardinalidades dispares: -2 puntos en el dataset afectado.
- Artefacto sobre `X_test` en orden distinto al original: invalida el dataset (0 puntos en ese dataset).